RAPPORT DE MINI-PROJET

Système Intelligent d'Estimation de la Valeur Marchande

des Joueurs de la Premier League (24/25)

Réalisé par :

Ayoub ZOUITINE

Prof :

M.Tarek AIT BAHA

Module :

Systèmes Intelligents

Année académique : 2025-2026

Introduction

Contexte

L'industrie du football est devenue un marché économique majeur où les transactions de joueurs atteignent des montants astronomiques. L'estimation de la valeur marchande d'un joueur est donc une problématique cruciale pour les clubs, les agents et les analystes sportifs. Cette valeur ne dépend pas uniquement des statistiques brutes, mais aussi de facteurs contextuels comme le club, le poste occupé et l'impact médiatique du joueur.

Objectif

L'objectif de ce projet est de concevoir et de déployer une application web interactive capable de prédire la valeur marchande d'un joueur de la Premier League pour la saison 2024-2025. Le système s'appuie sur deux modèles d'apprentissage automatique (Machine Learning) pour offrir une estimation précise et comparative.

1. Exploration et Prétraitement des Données

Source des données

Le jeu de données utilisé contient les statistiques détaillées des joueurs de la Premier League pour la saison en cours (minutes jouées, buts, passes décisives, tacles, etc.) ainsi que leur valeur marchande actuelle. Ces données constituent la base d'entraînement et d'évaluation des modèles développés.

Étapes de prétraitement (Pipeline)

Pour rendre les données utilisables par les modèles d'intelligence artificielle, un pipeline de prétraitement rigoureux a été mis en place, composé des étapes suivantes :

Étape	Description
Nettoyage	Traitement des valeurs manquantes et suppression des données aberrantes.
Encodage Catégoriel	One-Hot Encoding : Les variables qualitatives ("Club", "Poste") ont été transformées en variables binaires (0 ou 1). Ex. : "Club" -> "Club_Arsenal", "Club_Liverpool", etc.

Normalisation	Scaling : Les variables numériques (Buts, Minutes, etc.) ont été normalisées entre 0 et 1, évitant qu'une variable à forte valeur ne domine artificiellement les autres.

2. Développement et Entraînement des Modèles

Dans le notebook Jupyter, deux modèles d'IA ont été développés pour cette tâche de régression.

Modèle 1 : Régression Linéaire (Base)

Ce modèle établit une relation mathématique linéaire simple entre les caractéristiques d'un joueur et sa valeur marchande. C'est un modèle transparent et facile à interpréter, qui sert de référence (baseline) pour évaluer la performance des modèles plus complexes.

Modèle 2 : Random Forest (Forêt Aléatoire)

Ce modèle est plus complexe et robuste. Il crée une multitude d'arbres de décision et moyenne leurs prédictions. Il est capable de capturer des relations non linéaires et des interactions complexes entre les statistiques. Par exemple, l'impact d'un but n'est pas identique pour un défenseur et pour un attaquant.

Résultats d'entraînement

Les modèles ont été évalués en utilisant deux métriques complémentaires :

Métrique	Régression Linéaire	Random Forest
R^2 (Coefficient de détermination)	—	**Supérieur**
MAE (Erreur Absolue Moyenne)	—	**Meilleure**

Le Random Forest a démontré des performances supérieures, en capturant mieux la complexité des prix du marché grâce à sa capacité à modéliser des relations non linéaires entre les variables.

3. Déploiement : L'Interface Streamlit

Le cœur de ce projet réside dans l'accessibilité des modèles. Une application web interactive a été créée à l'aide de la bibliothèque Streamlit, hébergée localement dans un environnement virtuel Python pour garantir la portabilité et la reproductibilité du projet.

L'interface se divise en deux parties : une barre latérale pour la configuration des paramètres du joueur, et une zone principale pour l'affichage du résultat de la prédiction.

3.1 Démonstration : Prédiction avec la Régression Linéaire

Prenons l'exemple du joueur fictif Declan Rice. Avec les statistiques suivantes (poste de Milieu, 11 buts, etc.), le modèle de Régression Linéaire retourne une estimation de :

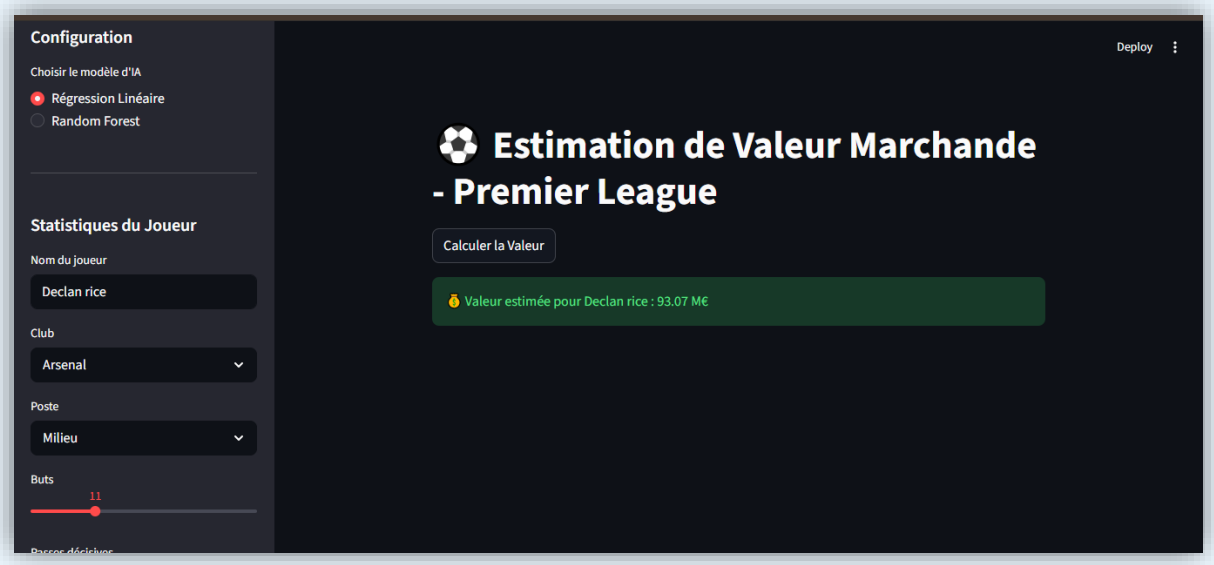

Valeur estimée (Régression Linéaire) : **93,07 M€**

Figure 1 : Prédiction via le modèle Régression Linéaire (image_8.png)

3.2 Démonstration : Comparaison avec le Random Forest

En conservant exactement les mêmes statistiques pour Declan Rice et en changeant uniquement le modèle sélectionné dans la barre latérale, le Random Forest fournit une estimation différente :

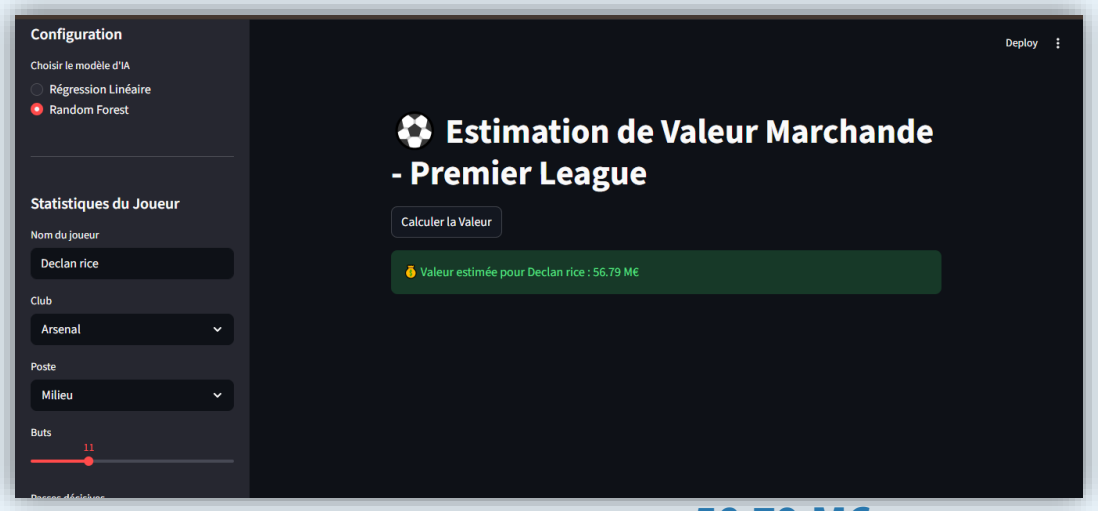

Valeur estimée (Random Forest) : **56,79 M€**

Figure 2 : Prédiction via le modèle Random Forest (image_9.png)

3.3 Analyse de la comparaison

Cette différence de prédiction constitue un point clé de l'analyse du système. Deux interprétations principales s'en dégagent :

- La Régression Linéaire donne une valeur plus élevée (93,07 M€), probablement parce qu'elle surévalue l'impact linéaire des 11 buts marqués par un milieu de terrain, sans tenir compte du contexte global.
- Le Random Forest est plus conservateur (56,79 M€). Il prend en compte les interactions complexes entre les variables (minutes jouées, tacles, impact défensif) pour affiner l'estimation, ce qui peut conduire à une valeur plus proche de la réalité du marché pour ce profil de joueur.

Conclusion et Perspectives

Ce mini-projet a permis de développer une chaîne complète de Machine Learning, depuis le prétraitement des données jusqu'à un déploiement web interactif et accessible.

Principales réalisations

- Nettoyage et normalisation des données de football issues de la Premier League.
- Entraînement et comparaison de deux modèles distincts (Régression Linéaire vs Random Forest).
- Création d'une interface web conviviale via Streamlit permettant une utilisation immédiate des modèles.

Limites identifiées

Bien que fonctionnel, le système présente plusieurs limites importantes :

- Le modèle ne prend pas en compte des facteurs cruciaux tels que l'âge du joueur, l'historique des blessures ou la durée restante de son contrat.
- Les données ne couvrent qu'une seule saison, ce qui peut biaiser l'estimation pour les joueurs en fin de carrière ou les jeunes espoirs en progression.

Améliorations futures

Plusieurs pistes d'amélioration ont été identifiées pour enrichir le système :

- Intégrer des variables supplémentaires (âge, blessures, durée de contrat) pour améliorer la précision des estimations.
- Utiliser des données multi-saisons pour capturer les tendances temporelles et les progressions de carrière.
- Déployer l'application en ligne sur un service cloud (Heroku, Streamlit Cloud, AWS) pour la rendre accessible à tous sans installation locale.
- Explorer des modèles plus avancés comme XGBoost, LightGBM ou des réseaux de neurones profonds pour améliorer encore les performances.